

Comparação de Arquiteturas de Redes Neurais Artificiais para Regressão e Predição de Temperatura na cidade de Bambuí (MG)

Guilherme Maciel da Rocha¹, Marco Aurélio Monteiro Lima¹, Ciniro A. L. Nametala²

¹Estudantes de Bacharelado em Engenharia de Computação – Instituto Federal de Educação, Ciência e Tecnologia (IFMG) – Campus Bambuí.

²Departamento de Engenharia e Computação – Instituto Federal de educação, ciência e tecnologia (IFMG) – Campus Bambuí.

marcomontteirok13@gmail.com, guilhermemacielr@hotmail.com,
ciniro@ifmg.edu.br

Resumo. Sabe-se que a oscilação da temperatura ocorre devido ao movimento do planeta Terra e aos fenômenos naturais, contando estes com as especificidades de cada estação do ano a depender de sua localidade. Compreender a existência dessas variáveis possibilita uma maior precisão da análise dos gráficos que pretendem elaborar uma previsão de tais temperaturas ao longo do ano. Ao mesmo tempo, por conta disso, haverá certo grau de incerteza nos resultados que, todavia, não impossibilitam que seja feita determinada previsão de temperatura por meio das Redes Neurais Artificiais (RNAs). Desta forma, o trabalho pretende comparar quatro diferentes arquiteturas de Redes Neurais Artificiais, com o intuito de obter, ao final, a arquitetura com melhor desempenho na predição. Importante destacar que os dados utilizados para o treinamento dessas RNAs são provenientes do Instituto Nacional de Meteorologia (INMET), responsável pelo monitoramento, análise e previsão do tempo e do clima brasileiros a partir de pesquisas que objetivam resultados práticos e confiáveis. A previsão do presente estudo diz respeito ao ano de 2016, tendo como pressuposto o histórico de dados de 2015 da cidade de Bambuí – Minas gerais, disponibilizados pelo INMET. Por fim, importante ressaltar que se fez uso da linguagem R para o desenvolvimento do experimento, junto ao Software RStudio. Como resultado obteve-se a rede Elman com melhor desempenho.

Palavras-chave: Rede Neural Artificial; Temperatura; Serie Temporal; Predição;

Abstract. . It is known that the temperature oscillation occurs due to the movement of the planet Earth and natural phenomena, counting these with the specificities of each season of the year depending on their locality. Understanding the existence of these variables allows a greater precision of the analysis of the graphs that intend to elaborate a forecast of such temperatures throughout the year. At the same time, of course, there will be some degree of uncertainty in the results, which, however, do not preclude a certain

temperature forecast by means of Artificial Neural Networks (RNAs). In this way, the work tries to compare four different architectures of Artificial Neural Networks, in order to obtain, in the end, the architecture with better performance in the prediction. It is important to note that the data used for the training of these RNAs come from the National Institute of Meteorology (INMET), responsible for the monitoring, analysis and forecasting of Brazilian weather and climate based on research that aims at practical and reliable results. The forecast of the present study refers to the year 2016, having as budget the historical data of 2015 of the city of Bambuí - Minas Gerais, made available by INMET. Finally, it is important to note that the R language was used for the development of the experiment, together with the RStudio Software. As a result the Elman network with the best performance was obtained.

Keywords: Artificial Neural Network; Temperature; Temporal Series; Prediction;

1. Introdução

Em mercados onde os resultados fazem diferença, prever os resultados futuros é uma informação muito valiosa. Quando se pode estimar, com certo grau de confiança, algum valor, como a quantidade de vendas em uma empresa, ou quantos graus irá fazer em um determinado dia, é possível se preparar para alguma situação que possa acontecer. Mas essas previsões não auxiliam apenas o mercado, é possível também estimar, consumo de energia de uma casa, resultados de partidas de futebol, classificação de tipos de flores, vidros, vinhos, entre outras aplicações.

Uma etapa imprescindível no processo de previsão é a decisão do modelo que será utilizado. Na análise de séries temporais existem diversos modelos que podem ser usados, porém, deve-se observar os dados para escolher qual modelo se enquadra melhor.

Nesse caso será usado quatro arquiteturas de redes neurais, a Multilayer Perceptron (MLP), *Radial Basis Function* (RBF), Elman e Jordan, e o objetivo será otimizar os resultados da previsão de temperatura da cidade de Bambuí, localizada em Minas Gerais. A série temporal analisada é composta por 731 dados, com três atributos cada: Data, umidade e temperatura, que foram registradas todos os dias, a partir do dia primeiro de janeiro de 2015 até dia 31 de dezembro de 2016.

A linguagem escolhida para fazer a implementação da rede neural foi a linguagem R, onde será usado o software Rstudio para auxílio da mesma. Este software foi escolhido pois possui muitas ferramentas úteis para plotagem dos gráficos e para análise dos dados.

2. Redes MLP, RBF, Elman e Jordan

2.1 Multilayer Perceptron

A MLP ou PCM em português, é uma rede de múltiplas camadas, como o próprio nome já diz, e ela é conectada com conexões *feedforward*, ou seja, as camadas estão estruturadas em uma sequência e os neurônios de uma camada influencia todos os neurônios da próxima camada (THOMÉ, 2003). Porém, os neurônios de uma mesma camada não se influenciam, e nem os da camada anterior. A figura 1 mostra como é uma MLP.




Figura 1: Rede MLP

Sua função de ativação é sigmoideal e o treinamento é feito através de *backpropagation* (retro propagação) para todas as camadas. O treinamento da *backpropagation* consiste em um algoritmo supervisionado estático, ou seja, a arquitetura é previamente conhecida, e não muda durante o treinamento. A figura 2 mostra as duas fases, em que é considerada uma configuração de MLP constituída de duas camadas escondidas, composta de n sinais em sua camada de entrada, tendo ainda n_1 neurônios na primeira camada neural escondida, n_2 neurônios na segunda camada neural escondida e n_3 sinais associados à camada neural de saída (terceira camada neural).




Figura 2: As duas fases de treinamento da MLP.

A primeira fase a ser aplicada é denominada de *forward*, na qual os sinais $\{x_1, x_2, \dots, x_n\}$ de uma amostra do conjunto de treinamento são inseridos nas entradas da rede e são propagados camada a camada até a produção das respectivas saídas. Logo em seguida, as respostas produzidas pelas saídas da rede são comparadas com as respectivas respostas desejadas que estejam disponíveis, pois, trata-se de um processo de aprendizado supervisionado.

Os respectivos erros entre a resposta desejada e aquelas produzidas pelo neurônios de saída estão calculados, os quais serão subsequentemente utilizados para ajustar os pesos de todos os seus neurônios. Assim, em função desses valores de erros, aplica-se, em seguida, a segunda fase do método *backpropagation*, denominada de *backward*. Diferentemente da anterior, as alterações (ajustes) dos pesos sinápticos de todos os neurônios da rede são executadas no decorrer desta fase.

Em suma, as aplicações sucessivas das fases *forward* e *backward* fazem com que os pesos sinápticos dos neurônios se ajustem automaticamente em cada iteração, e conseqüentemente o erro converge a mais próximo de zero.

2.2 RBF (Radial-Basis Functions)

As redes neurais artificiais do tipo *Radial Basic Functions* (RBFs) são redes supervisionadas, consideradas aproximadoras universais, assim como as MLPs (CASTRO). Ela possui três camadas: a camada de entrada conecta à rede ao ambiente, a camada oculta aplica uma transformação não linear aos dados, nesse caso, a camada é composta por funções radiais e a camada de saída fornece a saída da rede para os dados de entrada. A figura 3 representa a topologia dessa rede. Quando a RBF é usada para classificar um padrão complexo a mesma transforma o problema em um espaço não linear. A função geralmente utilizada para a rede é gaussiana.




Figura 3: Topologia para a rede RBF.

Na figura 4 abaixo, é possível ver na imagem à esquerda, a separação de uma amostra feita por uma MLP que utiliza hiperplanos, e a imagem da direita é a separação da mesma amostra feita por uma rede RBF que utiliza hiper-elipsóides.




Figura 4: Diferença de separação da rede MLP e RBF.

Segundo Engel, a rede RBF possui uma arquitetura mais simples que a MLP, tendo apenas uma camada oculta, o que difere da MLP que pode ter várias camadas ocultas. Outra diferença importante é que a MLP pode ter várias funções de ativação na mesma rede, e os parâmetros da mesma são ajustados simultaneamente e na RBF existem duas etapas no treinamento, uma parte não supervisionada e a outra supervisionada.

Como dito anteriormente o treinamento da rede RBF é feito em dois estágios. O primeiro estágio é a fase onde determina as funções de base radial e é não-supervisionada. No segundo estágio são determinados os pesos da camada de saída e é feito métodos lineares para ajustar os pesos usando a regra de delta.

2.3 Elman e Jordan

As redes neurais Elman e Jordan são recorrentes, isto é, tem comportamento temporal dinâmico e suas saídas variam com o tempo. Ambas são redes derivadas da MLP, por possuírem uma rede tipo perceptron de múltiplas camadas.

A rede Elman possui unidades de entrada, intermediárias e de saída e ainda as unidades de contexto, como a maioria das redes recorrentes (ELMAN, 1990). As unidades de entrada e saída são as únicas que comunicam com o meio externo, sendo que a unidade de entrada funciona apenas como uma unidade de buffer (armazenamento). Já as unidades intermediárias possuem as funções de ativações que podem ser lineares ou não lineares. As unidades de saída somam os sinais que recebem. Por fim a unidade de contexto memoriza ativações anteriores da camada intermediária, e isso pode ser considerado um atraso. A recorrência da rede Elman é feita da camada intermediária para a camada de entrada. A figura 5 mostra a topologia da rede Elman.




Figura 5: Topologia da rede Elman.

Na rede Elman as ativações das unidades intermediárias e as entradas correntes são usadas como entrada para a rede. No primeiro estágio as entradas são propagadas para frente *feedforward*, para produzirem saídas. Logo em seguida a rede é treinada com o algoritmo de *backpropagation*. Depois do treinamento, as unidades de contexto salva as ativações feitas pela unidade intermediária.

Já na rede Jordan, existem apenas algumas diferenças em relação a rede Elman. Na rede Jordan a recorrência é feita das camadas de saídas para a camada de entrada, e a

camada de contexto é realimentada pela camada de saída e pela própria camada de contexto (JORDAN, 1986). A figura 6 mostra a topologia da rede Jordan.




Figura 6: Topologia da rede Jordan.

3. Metodologia

Para avaliar o desempenho das quatro RNAs foi necessário treina-las com os dados disponibilizados pelo Instituto Nacional de Meteorologia (INMET), responsável pelo monitoramento, análise e previsão do tempo e do clima brasileiros. Esse conjunto de dados possui três atributos: data, umidade e temperatura máxima.

Inicialmente, foi verificado a presença de outliers, que são dados que apresentam um afastamento dos demais. Estes outliers correspondem aos dados de umidade do ano de 2015, detectados por meio de boxplots e plotagem de gráficos e a partir disso foram ajustados para um melhor aproveitamento das redes, concentrando seu funcionamento nas informações mais relevantes. A figura 7 compara duas figuras que revelam a diferença entre os gráficos com boxplots e outliers e aqueles que não contam com a presença deste último.

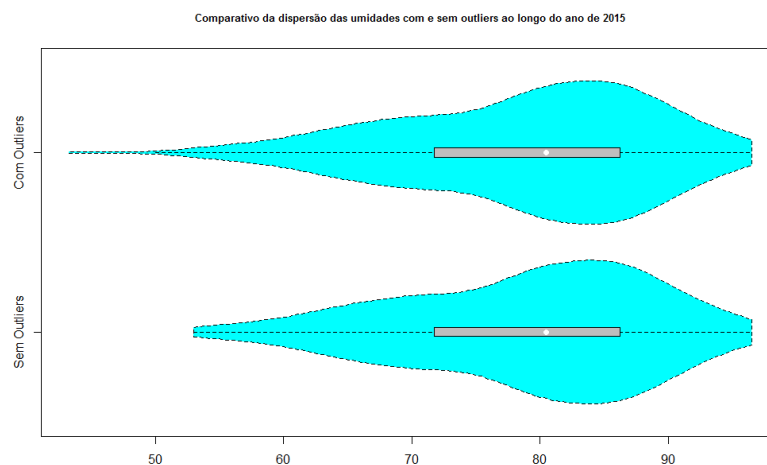


Figura 7: Comparação da dispersão das umidades com e sem outliers ao longo de 2015.

É possível notar na figura 7 que entre 75 e 95 existe uma frequência maior de ocorrências de umidade, assim como também é possível observar o ajuste dos dados após a retirada dos outliers. Visando um melhor entendimento, foi gerado o gráfico da figura 8 para evidenciar o outlier. Na passagem do verão para o outono a umidade alcança um equilíbrio, que se perde no momento do fim do inverno e começo da primavera.




Figura 8: Comparação entre os dados da umidade analisados com e sem outlier.

O mesmo foi feito com os dados de temperatura, porém esses não possuíam outliers, como mostra o boxplot da figura 9. Por isso é possível notar que após o ajuste ambos permaneceram idênticos.

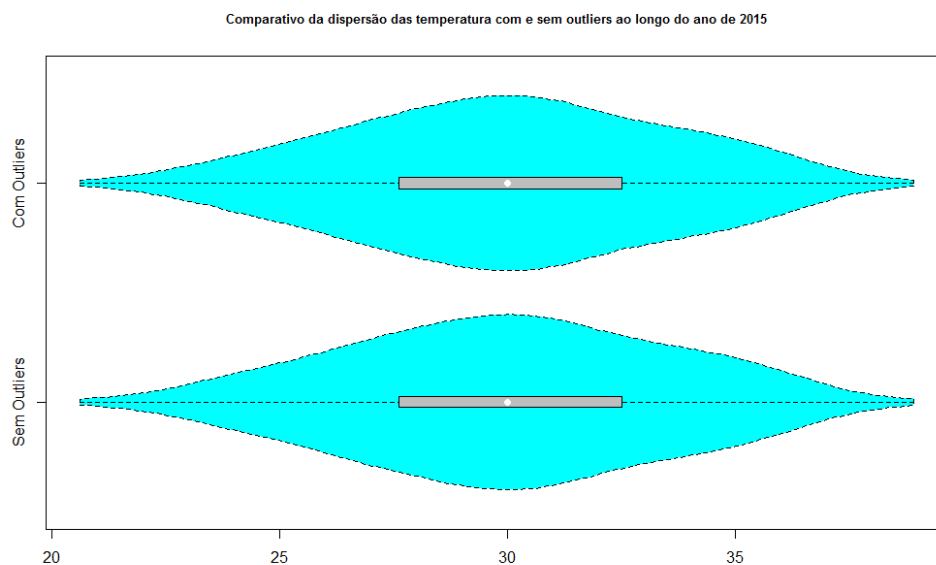


Figura 9: Comparativo da dispersão da temperatura com e sem outliers ao longo de 2015.

Da mesma forma, foi gerado o gráfico da figura 10 para a temperatura, onde é possível notar a ausência de outliers. Constata-se também durante que durante as estações da primavera e verão a temperatura é mais elevada, ao passo que no outono e inverno ela diminui.




Figura 10: Gráfico comparando a umidade com outlier e sem outlier.

Após todo o processo de ajuste de dados, eles foram padronizados, ou seja, foram transformados em números entre 0 e 1 para melhor performance no treinamento. Neste momento, foi feito o treinamento para as quatro arquiteturas de redes neurais através das configurações listadas na tabela 1.

Tabela 1: Configuração das quatro arquiteturas na primeira etapa.

Rede	Número Neurônios	Número épocas	Taxa de aprendizagem	Função de aprendizagem	Função de atualização	Aleatorização Dados	Linout
MLP	38	15000	0.008	Std_Backpropagation	Topological_Order	TRUE	FALSE
RBF	38	15000	1e-05, 0, 1e-05, 0.2, 0.8	RadialBasisLearning	Topological_Order	TRUE	FALSE
ELMAN	38	15000	0.008	JE_BP	JE_Order	TRUE	FALSE
JORDAN	38	15000	0.008	JE_BP	JE_Order	TRUE	FALSE

Na tabela 1, foi utilizado o mesmo número de neurônios e épocas para todas as quatro redes. O primeiro balanceamento foi feito pela MLP, ou seja, as outras redes estão

usando os mesmos dados que, quando não é possível utilizá-los, faz-se uso do valor padrão. A rede Elman tem muitos parâmetros parecidos com o da rede Jordan, pois ambas são redes recorrentes.

A convergência de erro da MLP pode ser visualizada na figura 11. A curva foi ajustada durante o balanceamento, onde os valores do número de neurônios, a taxa de aprendizagem e o número de épocas são alterados com a finalidade de encontrar a melhor curva para o erro.




Figura 11: Convergência do erro da MLP.

Após esse balanceamento, foi gerado um gráfico para prever a temperatura de 2015, em que devemos analisá-lo a fim de verificar se a rede MLP teve um bom desempenho. A partir da figura 12, é visível que ela teve um índice muito bom na previsão.

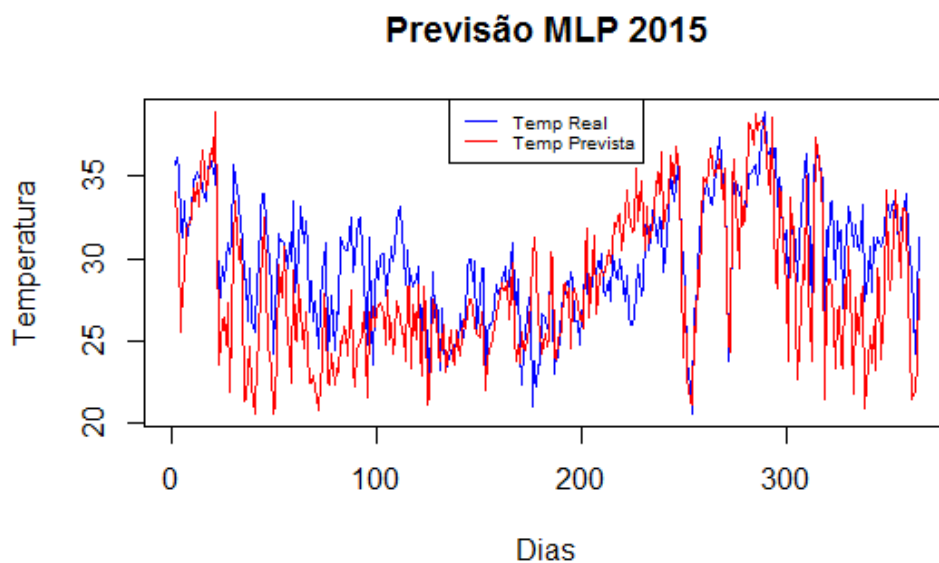


Figura 12: Previsão da MLP em 2015 após o treinamento.

Ao término do treinamento, todas as redes já podem prever a temperatura ao longo do ano de 2016 e serem comparadas com o intuito de indicar qual delas obteve o melhor desempenho por meio do erro quadrático médio. A tabela 2 mostra os EQM de cada rede.

Tabela 2: Erro quadrático médio de cada rede.

Rede	Erro quadrático Médio (EQM)
MLP	3.074 °C
RBF	2.996 °C
ELMAN	2.904 °C
JORDAN	3.132 °C

Sendo assim, conclui-se que a rede que obteve o menor erro foi a rede Elman, com 2.904 °C, que é um erro relativamente baixo quando leva-se em conta a complexidade dos dados. Foi plotado o gráfico com a temperatura máxima real e aquela prevista pela rede, como visto na figura 13.

Previsão 2016 com ELMAN




Figura 13: Previsão da ELMAN ao longo de 2016.

A curva de cor verde na figura 13 representa o LOWESS, que é uma curva suavizada em cada variação de dado, ou seja, ela consegue prever os vales e os picos de forma muito próxima da real.

4. Conclusão

Com os estudos realizados, pode-se auferir que as redes neurais artificiais são de grande utilidade na vida prática, quando há o interesse em prever determinados acontecimentos. Comparando as quatro arquiteturas de RNAs, notou-se que a rede Elman apresentou os resultados mais satisfatórios. Uma vez que ela faz parte das redes recorrentes, o resultado não é inesperado haja vista que estas são comumente mais eficazes que as redes tradicionais.

Contudo, é de suma importância ressaltar que como as redes MLP e RBF são de tipos diferentes da Elman e Jordan, não foi possível fazer uma comparação exata. Mas como dito, a rede Elman por ser recorrente se destacou das demais.

5. Referências

SILVA, Ivan Nunes da; FLAUZINO, Rogerio Andrade; SPATTI, Danilo Hernane. **Redes neurais artificiais para engenharia e ciências aplicadas – Curso Prático**. 1. ed. Artliber, 2010. 399 p.

Inteligência Computacional. Disponível em: <http://equipe.nce.ufrj.br/thome/grad/nn/mat_didatico/aula11.pdf>. Acesso em: 02 jun. 2017.

ENGEL, Paulo Martins. **Redes Neurais: A Rede RBF**. Disponível em: <<http://www.inf.ufrgs.br/~engel/data/media/file/cmp121/rbf.pdf>>. Acesso em: 04 jun. 2017.

CASTRO, Fernando César C. de; CASTRO, Maria Cristina F. de. **Radial Basis Function**. Disponível em: <http://www.feng.pucrs.br/~decastro/pdf/RNA_C5.pdf>. Acesso em: 04 jun. 2017.

GOMES, Herman Martins. **Reconhecimento de Padrões e Redes Neurais**. Disponível em: <http://www.dsc.ufcg.edu.br/~hmg/disciplinas/graduacao/rn2017.1/Aula08_PR&NN_HPAnalytics2012.pdf>. Acesso em: 04 jun. 2017.

Redes neurais artificiais recorrentes aplicadas na correção de sinais distorcidos pela saturação de transformadores de corrente. Disponível em: <http://www.scielo.br/scielo.php?script=sci_arttext&pid=S0103-17592006000400004>. Acesso em: 04 jun. 2017.